

그린가이드 AI — 모델·추론 파이프라인 기술 문서

v1.0 · 2026-08-06 · 작성: 개발 세션 실측 기반 (waste-classifier / waste-api / waste_app)
적용 버전: 모델 hier_v2 (레지스트리 v20260805_152341) · 서버 facc879 · 앱 88MB 슬림 빌드

1. 시스템 개요

그린가이드는 사진 한 장으로 폐기물의 재질을 분류하고 거주 지자체 조례 기준의 배출 방법을 안내하는 시스템으로, **클라우드 경로**(FastAPI 서버, 전체 파이프라인)와 **온디바이스 경로**(Flutter 앱 내 ONNX 단일 패스)의 이원 구조를 갖는다. 두 경로는 **동일한 분류기 가중치**를 공유하며, 차이는 추론 파이프라인(TTA·시맨틱 융합·VLM 중재 유무)에 있다. 설계 우선순위는 ① 분류 정확도 ② 반환 속도이다.

	클라우드 (기본)	온디바이스
실행 위치	HF Spaces (FastAPI, cpu-basic)	앱 내 onnxruntime
모델 전달	Docker 이미지 내장	OTA — HF Hub에서 다운로드 (번들 없음)
파이프라인	EXIF TTA + OCR/CLIP/CAM 융합 + OOD 게이트 + VLM 중재	단일 패스 + 게이트 롤업
평균 지연 (실측)	1.7 s	0.1-0.3 s
부가 기능	탭 재분류·빗금 실루엣·증거 칩·지역 조례 안내·피드백 수집	오프라인 분류만

2. 모델 인벤토리

모델	구조/크기	사용 경로	역할·비고
계층 분류기 (주 모델)	ResNet50 백본 · 94.4MB ONNX (FP32)	공통 (동일 가중치)	대분류 14 × 세부 25 (fine 로짓 → coarse 롤업). CAM 헤드 동시 출력 (conv2d 재구성 — 양자화 호환). 온디바이스는 HF Hub 에서 같은 발행본을 OTA 로 수신.
Stage1 이진 게이트	경량 CNN	클라우드 전용	폐기물/비폐기물 선별 — 통과 시 분류기의 non_object 로짓 마스크 (대분류 +5.9pp 실측)
u2netp	4.4MB ONNX	클라우드 전용	saliency — 객체 마스크·성분 분리(watershed-lite)·다중 물건 후보
CLIP 이미지 인코더	INT8 ONNX + 컨셉 임베딩 66개	클라우드 전용	정체(identity) 인식 — 제로샷 컨셉 매칭, 한국어 증거 토큰
RapidOCR	PP-OCRv5 korean mobile	클라우드 전용	라벨 문구·분리배출 마크 텍스트 인식
DINOv2 분류기	ONNX (기본 비활성)	클라우드 전용	양상블 후보 — 홀드아웃 중립이라 WASTE_API_DINO_W=0

VLM 풀백	Claude Haiku 4.5 (API)	클라우드 전용	저확신·reject·증거불일치 시 최종 판정자. 일 200회 상한
GrabCut (모델 아님 — CV 알고리즘)	OpenCV	클라우드 전용	탭 지점 물건의 픽셀 실루엣 분리 — 탭 분류 크롭·빗금 영역

온디바이스 경로는 주 분류기 + taxonomy 게이트 롤업만 사용한다 — §7 비교의 격차가 곧 "파이프라인 차이"인 이유(가중치 동일).

3. 전처리·정규화

- **입력 정규화**: RGB → 224×224 **스트레치** 리사이즈(bilinear, 크롭 없음) → [0,1] 스케일 → ImageNet 통계 정규화 `mean=(0.485, 0.456, 0.406)`, `std=(0.229, 0.224, 0.225)`. 학습(Python)과 온디바이스(Dart) 구현이 동일 수치를 사용한다.
- **고해상 CAM**: 재질 영역 분석은 448×448 forward → 25클래스 × 14×14 CAM (셀당 16px).
- **EXIF 방향**: 학습 데이터(AI-Hub 크롭)는 센서 방향, 서빙 입력은 뷰어 방향 — 분포 불일치가 실측 정확도를 크게 훼손(26→36/51)하여 서빙에서 **회전 TTA**로 흡수한다(§5).
- **저장용 재압축**(수집 정책): EXIF 보정 + 긴 변 720px JPEG q80 — 장당 255KB→29KB 실측.

4. 학습 방법

- **데이터**: AI-Hub 생활폐기물(71385) 계층 크롭 + TACO 실외 실사 + 사용자 피드백. Kaggle류 스튜디오 이미지는 노이즈 부재로 기각.
- **계층 구조**: 대분류 14 / 세부 25 (`taxonomy.json` 사이드카가 정본 — fine→coarse 매핑·게이트·라벨 순서를 모델과 함께 배포).
- **손실**: fine CE + **rollup loss**(fine 확률 합산 → coarse CE) — 세부가 불확실해도 대분류가 견고하도록.
- **증강**: 표준 augment + **ROT90**(EXIF 방향 격차 완화).
- **신뢰도 게이트** (표시 깊이 결정): fine 확신 ≥ 0.60 그리고 마진 ≥ 0.15 → 세부 표시; coarse ≥ 0.55 → 대분류 표시; 미달 시 reject(기타). OOD prototype 거리 $\tau_{\text{soft}} 0.30$ (세부 억제) / $\tau_{\text{hard}} 0.40$ (완전 reject — 탭 경로에서는 완화).
- **평가 무결성**: 피드백 사진(`user_*`)은 학습에서 영구 제외 — 과거 31/51 오염으로 실측 지표가 부풀려졌던 사고 이후의 원칙. 게이트 승격/롤백은 support ≥ 50 클래스의 recall 저하만 거부권을 갖는다(etc↔trash 동치 처리).
- **지표 (hier_v2)**: frozen test coarse **96.4%** / fine **93.2%**, val coarse 94.3% / fine 90.2% (best epoch 9). 실사용(순수 홀드아웃)은 이보다 낮다 — §7.

5. 클라우드 추론 파이프라인과 최적화

운영 장면 경로 지연을 15s → 1.6s(9.4x)로 줄인 트랙과 정확도 융합 트랙의 조합이다. 순서대로:

단계	내용	최적화·근거
1. Stage1 게이트	폐기물 여부 판정	비폐기물 조기 종료, non_object 마스킹
2. 회전 TTA	EXIF 태그 기반 후보 회전만 추론, 최고 확신 채택	B2: 태그별 축소 — 6→(0°,90°), 8→(0°,270°), 3→(0°,180°), 무태그 3방향. 3x→평균 1.7x
3. 조건부 OCR	텍스트·마크 인식 → 어휘 부스트 (A급 마크 ×6, B급 정체어 ×2.5)	B1: 1차 확신 ≥ 0.75면 스킵 (운영 -2~4s). 탭 경로는 항상 수행
4. CLIP·CAM prior	정체 인식 prior(부스트 전용, 비율 상한 8) + 탭 영역 CAM prior(w=0.15)	탭(고립 크롭) 전용 — 장면 적용은 실측 역효과
5. 융합 재예측	prior 를 로그-선형 곱 후 베스트 회전 텐서 1장만 재예측	TTA 전체 재실행 대비 1회로 절감
6. VLM 중재	reject·coarse<0.55· 증거-불일치 (강한 CLIP 증거가 다른 대분류 지시) 시 Claude Haiku 최종 판정	재질 교체는 확신 ≥ 0.8, non_object 는 ≥ 0.5 (과신 가드). 일 200회 상한, 실패 시 무시(fail-open)

- **기각된 최적화:** INT8 양자화(주 모델) — QUInt8/per-channel에서 정확도 -1~5pp라 채택 안 함 (CLIP 인코더만 INT8). u2netp 자동 크롭(장면 경로) — v6+TTA 하에서 역효과(39→25)라 전체 프레임 사용.
- **탭-투-셀렉트 경로:** GrabCut(탭 중심 창, ≤480px)으로 물건 실루엣을 픽셀 수준 분리 → 분류 크롭·빗금 영역 모두 실루엣 기반. 탭 = "물체 존재" 신호이므로 OOD 하드 reject 를 소프트(대분류 표시)로 완화. 크롭 최소 변 35% 보장(파편 크롭 방지).

6. 온디바이스 파이프라인

- **OTA 전달:** 번들 모델 제거(앱 204→88MB, Play 200MB 한도 대응). 앱이 /model/latest → HF Hub(ethanDev92/waste-models)에서 ONNX + taxonomy 사이드카를 받아 캐시. sha256 검증, 실패 시 구캐시 → 클라우드 폴백.
- **추론:** 단일 패스 (TTA·융합·VLM 없음, non_object 마스킹 없음) → fine 확률 → 게이트 롤업 — 서버 /predict-hier 와 동일한 의미의 표시 수준(fine/coarse/reject)을 재현.
- **폴백 정책:** 온디바이스 저확신 시 클라우드에 재판정 위임(오프라인이면 로컬 결과 유지). 기본 모드는 클라우드.

7. 온디바이스 vs 클라우드 — 실측 비교 (2026-08-06)

피드백 라벨이 확정된 실사용 사진 51장을 **동일 가중치·양 경로**로 평가. 대분류(coarse) 기준 채점. hier_v2 학습에 포함됐던 33장(낙관 편향)과 학습에 없던 **정직 서브셋 18장**을 분리 집계.

세트	온디바이스	클라우드	격차	reject (dev/cloud)
----	-------	------	----	--------------------

전체 (n=51)	31/51 = 60.8%	28/51 = 54.9%	-5.9pp	13 / 17
정직 서브셋 (n=18)	8/18 = 44.4%	8/18 = 44.4%	±0.0pp	5 / 9
학습 포함분 (n=33, 참고)	23/33 = 69.7%	20/33 = 60.6%	-9.1pp	8 / 8
평균 지연	0.1-0.3 s	1.7 s		

해석. 대분류 정답률만 보면 두 경로는 **사실상 동률**이다(정직 서브셋 ±0.0pp). 클라우드의 걸보기 열세(전체 -5.9pp)는 대부분 보수적 reject 정책에서 온다 — OOD 하드 게이트와 VLM이 저확신 케이스를 "기타/재촬영"으로 돌려보내는 건수가 더 많다(17 vs 13). 이는 오답을 정답처럼 확신 있게 표기하는 것보다 안내 품질 면에서 의도된 동작이지만, 단순 정답률 지표에서는 손해로 나타난다.

한계. ① 이 채점은 클라우드 전용 가치(탭 재분류, 빗금 실루엣, 증거 칩, OCR 텍스트가 있는 케이스의 부스트, 지역 조례 안내, 피드백 수집)를 포착하지 않는다 — 텍스트·마크가 있는 사진에서는 클라우드가 구조적으로 유리하다. ② n=18은 통계적으로 작다(±11pp 수준의 오차). ③ reject 를 "오답"으로 채점했다 — reject 후 재촬영 유도를 성공으로 보는 지표에서는 결론이 달라진다. 결론: 속도·오프라인은 온디바이스, 설명가능성·복합 장면·안내 품질은 클라우드 — 현행 기본값(클라우드 + 저확신 교차 폴백)이 타당하다.

8. 운영·용량 정책 (무료 티어 지속성)

자원	정책	가드
Supabase Storage (1GB)	업로드 재압축(720px q80, ~9×) · 피드백 없는 업로드 7일 후 자동 삭제 · user-uploads 버킷 비공개 (service key 접근)	사용률 80% 초과 위험 시 발행 ·작업 중단 후 보고
HF 모델 저장소	활성 버전만 유지(발행 시 구버전 자동 삭제) · 대용량 파일 호스팅 전담 (Supabase 무료 50MB/파일 캡 우회)	자체 상한 1GB 의 80% 초과 시 발행 중단
기기 (앱)	분류 기록 최근 100건 초과분 이미지·행 자동 정리 · 모델 캐시는 활성 버전만	—
VLM 비용	일 200회 상한 (카운터 영속)	한도 도달 시 자동 스킵

디자인 토큰·컴포넌트 스펙: <https://ethandev92-waste-api.hf.space/design/tokens.json> · 모델 저장소: <https://huggingface.co/ethanDev92/waste-models> · 본 문서의 수치는 2026-08-06 실측 기준이며, 재학습·재평가 시 \$7은 갱신되어야 한다.